通过动作聚合后的 Fisher 信息损失
比较多智能体协调规则

Heath Li
Kunyanli230/Jevometry
面向 JAAMAS / arXiv 的工作稿
本文为 main.tex 的中文对应译本

October 11, 2026

Abstract

多智能体决策系统常常把感知——输出局部结果上范畴分布的专用智能体——与协调——把联合结果映射到小动作字母表（例如拒绝、自动应用、升级给人工）的确定性规则——分开。尽管感知模型与联合构造在 Dec-POMDP 主动感知与信息采集中已有仔细处理，协调层却经常由启发式设计，并仅通过任务奖励或吞吐量评估。本文提出一个互补问题：在智能体输出分布固定的前提下，哪些协调规则对底层参数销毁的 *Fisher* 信息最少？

我们将协调形式化为与 θ 无关的聚合映射 $A = f(Z)$，并用声明联合与其推前之间的 Fisher 信息数据处理间隙 $I_Z(\theta) - I_A(\theta) \succeq 0$ 量化信息损失。在 Jevometry 三智能体数据清洗委员会（适用性、修复、风险）及声明乘积联合下实例化该框架，我们在证据与歧义网格上比较七条纯规则——baseline、stricter、wider、quarantine-to-review、混合 quarantine-wider 拆分、粗粒度二元规则，以及近恒等上界。在设计中心点，baseline 协调约丢弃 $\mathrm{tr}(I_Z)$ 的一半；将 quarantine 软化为人工复核可挽回该损失的相当一部分；再与不同的 auto-normalize/auto-impute 标签组合，可在完整设计网格上进一步改进。粗化为二元 reject/proceed 闸门则损失更多。排序 near-identity $\leq$ wider $\leq$ baseline $\leq$ stricter 在每个网格单元上稳定；Δ_f 的参数轴分解表明 quarantine 软化主要保留歧义方向。我们讨论智能体委员会的设计含义、迫使确定性映射的 API 约束，以及解析 softmax 族相对在线决策模型 API 的局限。配套代码与可复现表格随 Jevometry 仓库一并提供。

1 引言

大语言模型与专用决策 API 使获取看起来已校准的局部判断范畴分布变得便宜：某修复是否适用、尝试何种修复、自动写入有多危险。在生产数据系统中，这些局部判断很少是最终产物。协调器——往往是一小段确定性业务逻辑——把智能体输出的联合压缩为可执行、可延期或可拒绝的最终动作 [Jevometry maintainers, 2026]。

这种压缩是信息瓶颈。经典决策理论与 Dec-POMDP 规划优化定义在信念或预测质量上的奖励 [Lauri and Oliehoek, 2020, Lauri et al., 2020, Oliehoek and Amato, 2016]。信息论多智能体感知最大化互信息或相关集函数，常带有子模贪婪保证 [Krause et al., 2008, Nemhauser et al., 1978, Corah and Michael, 2021, Shi et al., 2026]。这些工作选择观察什么或谁应观察。它们本身并不能告诉实践者：两条已部署的协调规则中，哪一条对智能体设计所跟踪的参数保留更多敏感性。

Fisher 信息为这种敏感性提供了局部、可微的语言 [Fisher, 1925, Amari, 2016]。对具有得分 Jacobian J_Z 的离散模型 $P_\theta(Z)$，Fisher 矩阵 $I_Z = J_Z^\top \mathrm{diag}(P_\theta)^{-1} J_Z$ 度量无穷小参数移动如何强烈改变结果分布。当固定映射 f 产生动作 $A = f(Z)$ 时，Fisher 信息的数据处理不等式在标准正则条件下断言 $I_Z - I_A \succeq 0$ [Zamir, 1998, Cover and Thomas, 2006]。当 I_Z 固定时，标量 $\mathrm{tr}(I_Z - I_A)$ 便是可比较的损失摘要。

贡献。

1. 我们将多智能体协调规则比较表述为：在共享声明联合下，按 Fisher 信息损失对与 θ 无关的聚合映射排序（第 3 节）。

2. 我们在 Jevometry 清洗委员会中实例化七条纯规则，并提供可复现实验装置：扫描参数网格、导出 CSV/JSON（含参数轴损失对角元与分数损失），并生成发表用图（第 4 节）。

3. 经验上，在设计中心点 baseline 规则约损失 $\mathrm{tr}(I_Z)$ 的 44%；quarantine-to-review 相对 baseline 约削减四分之一损失；混合 quarantine-wider 规则进一步改进（$\mathrm{tr}(\Delta) \approx 2.16$）并在完整网格上优于 quarantine-to-review；二元闸门的损失高于更严的中风险拒绝（第 5 节）。

4. 我们讨论该度量如何补充以奖励为中心的 Dec-POMDP 评估，以及 API 约束（仅确定性映射）对未来可学习协调器的含义（第 6 节）。

本稿旨在作为伴随开源实验的短期刊 / arXiv 草稿。它并非关于在线清洗质量的主张；智能体族是解析且示意性的。

2 相关工作

Dec-POMDP 主动感知。 Lauri and Oliehoek [2020] 通过个体预测动作，将带预测奖励的多智能体主动感知约化为标准 Dec-POMDP 求解器，并给出去中心化损失界。Lauri et al. [2020] 在离散与连续状态设定下，用策略图改进优化凸信念依赖奖励（例如负熵）。两条线通常把团队视为固定，并把信息目标折入奖励，而非事后比较确定性协调器。

信息驱动的多智能体感知。 子模传感器选择与多机器人跟踪在单调性下以贪婪 $(1 - 1/e)$ 保证最大化互信息或相关覆盖目标 [Krause et al., 2008, Corah and Michael, 2021]。Shi et al. [2026] 在 Dec-POMDP 中为互信息目标联合选择智能体并综合感知策略。Olkin et al. [2024] 与 Molloy and Nair [2023] 进一步将规划连接到信息与平滑器熵。我们的设定是对偶的：智能体及其局部律固定；仅最后一英里到动作的映射变化。

面向智能体的信息几何。 Fisher–Rao 几何为参数化分布族提供局部度量 [Amari, 2016]。Jevometry 为智能体系统操作化节点级与系统级 Fisher 诊断 [Jevometry maintainers, 2026]。我们使用其推前 `information_loss` 原语，且不修改底层 DECLARED_PRODUCT 构造。

3 问题形式化

3.1 声明乘积联合

令 $\theta \in \Theta \subset \mathbb{R}^d$ 参数化多智能体系统。每个智能体 $i \in \{1, \dots, m\}$ 在有限局部字母表 $\mathcal{Z}_i$ 上发出范畴分布 $P_\theta(Z_i)$。声明乘积联合断言给定 θ 时的条件独立：

$$P_\theta(Z = z) = \prod_{i=1}^{m} P_\theta(Z_i = z_i), \qquad z = (z_1, \dots, z_m) \in \mathcal{Z} = \prod_i \mathcal{Z}_i. \tag{1}$$

在我们的清洗例子中，$m = 3$，$d = 2$，且 $\theta = (\text{evidence}, \text{ambiguity})$，坐标在 $[0, 1]$。该声明是模型假设，而非关于在线 API 的经验主张。

3.2 作为聚合的协调

定义 1 (协调规则)**.** 协调规则是映射 $f : \mathcal{Z} \to \mathcal{A}$，映入有限动作字母表 $\mathcal{A}$。若 f 仅是联合结果的全函数（无隐随机性），则称其为纯的；若 f 不依赖 θ，则称其为与 θ 无关的。

诱导的动作律是推前

$$P_\theta(A = a) = \sum_{z:f(z)=a} P_\theta(Z = z). \tag{2}$$

若 $J_Z(\theta)$ 是联合概率向量关于 θ 的 Jacobian，则聚合 Jacobian J_A 通过对共享同一动作标签的 J_Z 行求和得到。

3.3 Fisher 信息损失

定义 2 (规则的信息损失)**.** 对与 θ 无关的规则 f，定义

$$I_Z(\theta) = J_Z(\theta)^\top \mathrm{diag}\big(P_\theta(Z)\big)^{-1} J_Z(\theta), \tag{3}$$

$$I_A(\theta) = J_A(\theta)^\top \mathrm{diag}\big(P_\theta(A)\big)^{-1} J_A(\theta), \tag{4}$$

$$\Delta_f(\theta) = I_Z(\theta) - I_A(\theta). \tag{5}$$

我们报告 $\mathrm{tr}(I_Z)$、$\mathrm{tr}(I_A)$ 与 $\mathrm{tr}(\Delta_f)$ 作为标量摘要，并数值验证 $\Delta_f \succeq 0$（*PSD* 检查）作为数据处理诊断。

命题 1 (固定映射的 DPI)**.** 在标准正性与可微条件下，任意与 θ 无关的 f 满足 $\Delta_f(\theta) \succeq 0$。当 f 在 P_θ 的支撑上单射时等号成立。

注 1. 依赖 θ 的映射（软策略、以参数为条件的学习路由）落在 *Jevometry* 实现的该保证之外，并被报告为不支持。因此本文仅关注纯的、全覆盖的、与 θ 无关的规则——即匹配典型生产 *if-then* 协调器与库的 *AggregationMap* 契约的那一类。

比较原则。 固定智能体与联合构造。按 $\mathrm{tr}(\Delta_f)$ 对规则排序（越低越好），或等价地按 $\mathrm{tr}(I_A)$（越高越好）。因为 I_Z 共享，按损失排序与按保留信息排序相同。

4 方法与实验设计

4.1 三智能体清洗委员会

我们复用离线 Jevometry 教程 `examples/three_agent_cleaning` [Jevometry maintainers, 2026]。三个解析 softmax 智能体为噪声数值字段的单个候选修复产生分布：

智能体	原语	支撑
applicability	Noul	$\{\mathrm{false}, \mathrm{true}\}$
repair	Choice	$\{\mathrm{normalize}, \mathrm{impute}, \mathrm{quarantine}\}$
risk	Score	$\{0, 1, 2\}$（低/中/高）

局部 logit 在设计中心 $\theta_0 = (0.7, 0.3)$ 附近对 $(\theta - \theta_0)$ 为仿射，概率由 softmax 得到。联合是声明乘积（ConstructionMode.DECLARED_PRODUCT）。不查询任何在线 API；不执行实际数据库写入。

4.2 协调规则

我们比较七条规则，均为纯且与 θ 无关：

baseline 若不适用、quarantine 或高风险则拒绝；若 normalize 且低风险则自动应用；否则人工复核。

stricter 同 baseline，但中风险也拒绝。

wider 拒绝条件同 baseline；低风险 normalize 与 impute 成为不同的自动标签（`auto_normalize`、`auto_impu`

Table 1: 中心 $\theta_0 = (0.7, 0.3)$ 处的 Fisher 迹，按损失升序排列。 $|A|$ 为推前下具有正质量的动作数。

规则	$\mathrm{tr}(I_Z)$	$\mathrm{tr}(I_A)$	$\mathrm{tr}(\Delta)$	$\lvert A\rvert$	状态
near_identity	6.8418	6.8418	0.0000	18	ok
quarantine_wider	6.8418	4.6816	2.1602	4	ok
quarantine_review	6.8418	4.5764	2.2654	3	ok
wider	6.8418	3.8285	3.0133	4	ok
baseline	6.8418	3.8080	3.0338	3	ok
stricter	6.8418	3.4198	3.4220	3	ok
coarse_binary	6.8418	3.1296	3.7122	2	ok

quarantine_review Quarantine 路由到人工复核而非拒绝；仅在不适用或高风险时拒绝。

quarantine_wider Quarantine-to-review 与 wider 的双自动标签组合：本研究中经验上最强的粗策略。

coarse_binary 在 baseline 拒绝条件下拒绝；否则为单一 `proceed` 动作（自动应用与复核合并）。

near_identity 每个联合结果元组一个动作标签（18 个标签）：在该字母表下的 Fisher 保留上界。

4.3 实验装置

脚本 `paper_experiments.py` 一次构建节点与联合，在 evidence $\in [0.2, 0.9]$ 与 ambiguity $\in [0.1, 0.8]$ 的 8×8 网格上评估 I_Z、I_A 与 Δ_f，并额外记录精确中心 θ_0。输出：

- `papers/coord-fisher/data/rule_loss_grid.{csv,json}`
- `papers/coord-fisher/data/center_summary.json`
- `papers/coord-fisher/data/center_loss_anisotropy.csv`、`rule_loss_anisotropy_grid.csv`、分数损失热图
- `papers/coord-fisher/data/iteration_summary.json`
- 图 1–4，位于 `papers/coord-fisher/figures/`

`src/jevometry` 下的库代码未改动；仅扩展了示例级规则与脚本。

5 实验

5.1 中心点排序

表 1 报告 θ_0 处的迹。所有规则返回状态 `ok`，损失矩阵为 PSD。近恒等映射无损失（至多数值噪声），对照 DPI 等号情形确认实现。Baseline 损失 $\mathrm{tr}(\Delta) \approx 3.03$，出自 $\mathrm{tr}(I_Z) \approx 6.84$——约 44%。Wider 通过保留不同自动路径而略优于 baseline。更严的中风险拒绝增加损失。将 quarantine 软化为复核带来显著实际收益（$\mathrm{tr}(\Delta) \approx 2.27$）；将该软化与 wider 的双自动标签叠加以得到 `quarantine_wider`，进一步改进至 ≈ 2.16，是此处最佳的非恒等粗策略。坍缩为二元闸门在所列规则中最差（≈ 3.71）。

先前探索工作中强调的核心排序在 8×8 设计网格的每一个单元上（64/64）仍然成立，而不仅在中心（数值容差 10^{-9}）：

$$\text{near-identity} \;\leq\; \text{wider} \;\leq\; \text{baseline} \;\leq\; \text{stricter}$$

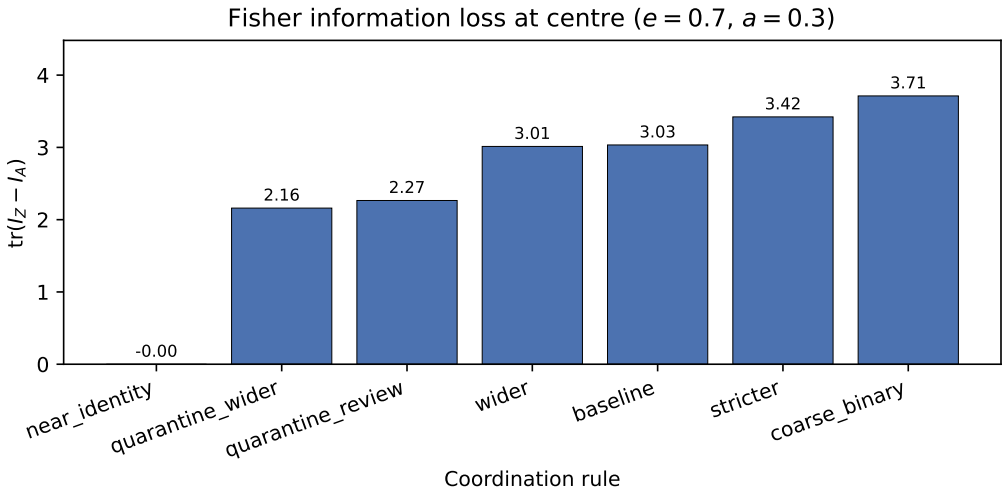


Figure 1: 设计中心处各规则的信息损失 $\mathrm{tr}(I_Z - I_A)$。



Figure 2: 五条协调规则在 evidence×ambiguity 上的损失热图。

Quarantine-to-review 在损失轴上插在 wider 之下；`quarantine_wider` 插得更低，并在 65/65 次记录的中心与网格评估上满足 $\mathrm{tr}(\Delta_{\text{quarantine_wider}}) \leq \mathrm{tr}(\Delta_{\text{quarantine_review}})$。 粗二元规则位于 stricter 之上——相对原先四规则故事的有信息偏离。

5.2 网格行为

图 2 给出五条非恒等规则在参数网格上的损失热图。绝对损失随 θ 变化，因为 $I_Z(\theta)$ 与跨 f-纤维的质量分配都在变，但定性排序在定义域的大片区域稳定：更软、更细的动作字母表比更严或二元闸门更“冷”（损失更低）。图 3 在歧义最接近 0.3 处切片损失对证据的关系；近恒等保持为零，而粗二元与 stricter 仍是损失最大的。

5.3 动作质量

图 4 显示中心处概率质量如何划分。Stricter 把中风险质量再分配到拒绝。Wider 把自动应用拆成 normalize 与 impute。Quarantine-to-review 缩小拒绝、偏向人工复核。粗二元把自动应用与复核折叠进 `proceed`。这些质量转移正是 Fisher 损失背后的机制：合并得分行相异的结果会坍缩可区分的参数方向。

5.4 各向异性与 quarantine-wider 机制

迹摘要掩盖了哪一参数方向被丢弃。在 θ_0，(evidence, ambiguity) 基下 Δ_f 的对角元表明：相对 baseline，`quarantine_review` 大约将歧义轴损失减半（$\Delta_{aa} \approx 0.95$ 对 ≈ 1.69），而证据轴损失保持可比。相对损失 $\mathrm{tr}(\Delta)/\mathrm{tr}(I_Z)$ 在网格上 $I_Z(\theta)$ 变化处保持相同排序。

推前质量解释混合收益：相对 `quarantine_review`，`quarantine_wider` 用不同的 `auto_normalize` 与 `auto_impute` 原子替换单一 `auto_apply` 原子，并把额外质量从 `human_review` 移入 `auto_impute`；`reject`

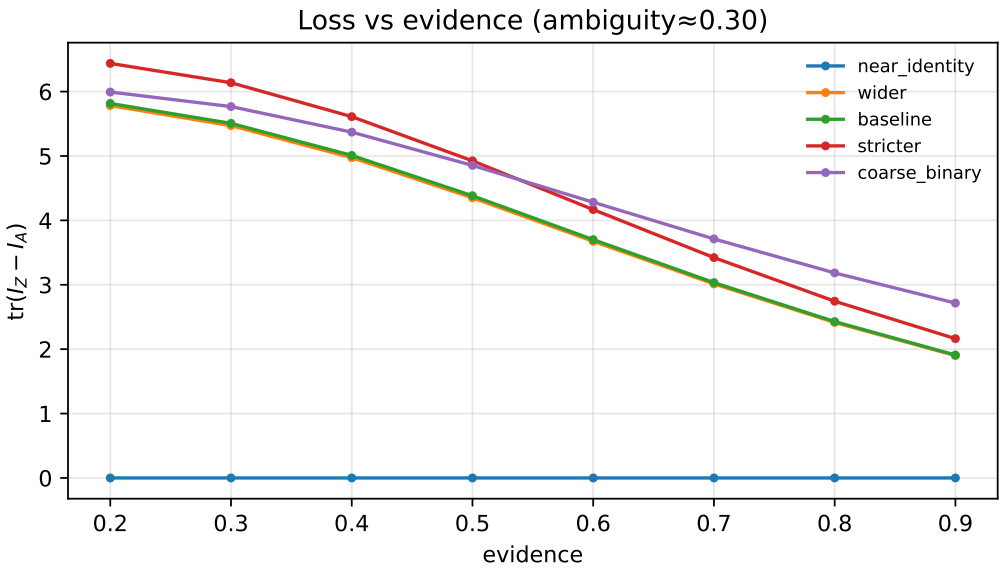


Figure 3: 在固定歧义约 0.3 处损失相对证据的变化。

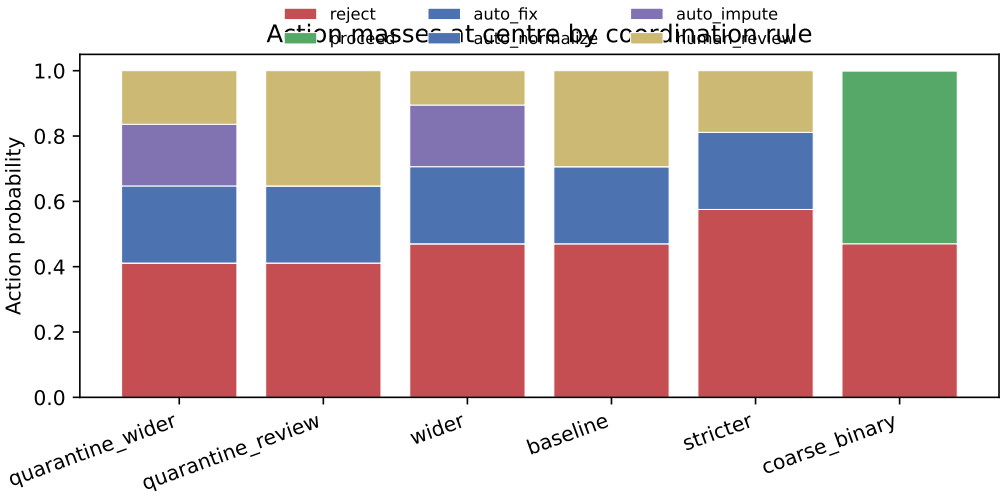


Figure 4: 非恒等规则在中心处的推前动作概率。

质量不变。更细的自动纤维保留了较粗复核规则所合并的得分行。

6 讨论

“一半 Fisher”意味着什么。 Baseline 协调后 $\mathrm{tr}(I_Z)$ 下降 44% 并不意味着系统“错了” 44%。它意味着：局部上，证据与歧义的无穷小变化对最终动作分布的推动，弱于对智能体输出联合的推动。若监控仪表盘只看动作率，就会低估底层委员会的敏感性。若下游估计器试图从动作反推 θ，其问题严格难于从 Z 反推。

设计要点。 在可实现的三/四动作策略中，将 quarantine 路由到复核比单独的 baseline 或 wider 保留更多 Fisher；将该软化与不同的 auto-normalize/auto-impute 标签组合，在本网格上仍严格更好。二元 proceed/reject 闸门在运维上方便，但在信息上昂贵。实践者在 A/B 测试前讨论规则变更时，可将 $\mathrm{tr}(\Delta_f)$——以及需要时其参数轴对角元——当作廉价的离线评分。

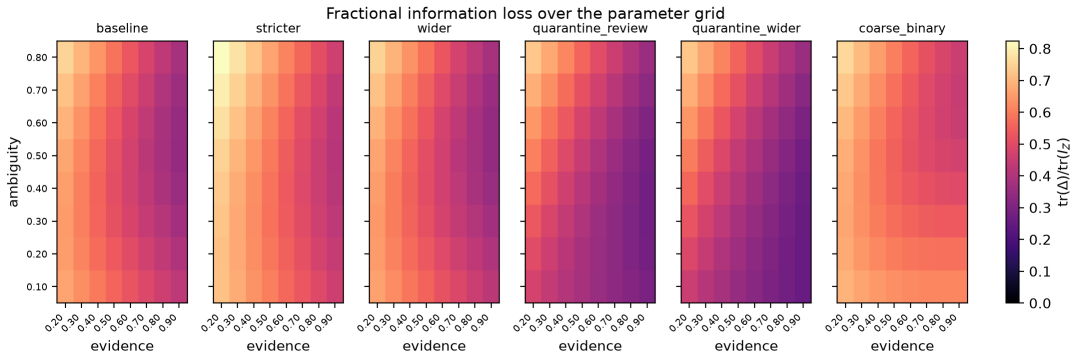


Figure 5: 非恒等规则在 evidence×ambiguity 网格上的分数损失 $\mathrm{tr}(\Delta)/\mathrm{tr}(I_Z)$。

与 Dec-POMDP 奖励的关系。 预测奖励与负熵目标 [Lauri and Oliehoek, 2020, Lauri et al., 2020] 优化感知策略。我们的度量并不取代它们；它在感知固定之后审计最后一道确定性压缩。就此意义而言，它与 IMAS^2 风格的联合选择 [Shi et al., 2026] 互补：选择扩展谁可以观察；协调排序追问这些观察有多少在动作层幸存。

API 约束。 许多智能体平台仅暴露采样结果加确定性业务规则。软的、依赖 θ 的路由器要么需要声明条件动作模型，要么拒绝 DPI 证书——正是 Jevometry AggregationMap 所编码的契约。将本研究扩展到随机协调器是未来工作，并需要额外正则性。

7 局限

- 智能体分布是手工指定的解析 softmax 族，而非拟合的在线决策模型。绝对数值是示意性的。
- 条件独立是声明的，而非检验的。
- 我们报告 Δ_f 的参数轴对角元与特征值，但完整 CRLB 式解读仍需要本例未提供的观测似然契约。
- 各规则的动作字母表不同；作为关于 θ 的保留信息，$\mathrm{tr}(I_A)$ 比较仍然有意义，但把 $|A|$ 当作效用的解释超出范围。
- 没有人工或任务奖励研究验证更低的 Fisher 损失会改善清洗结果。

8 结论

我们提出在共享声明联合下按 Fisher 信息损失对多智能体协调规则排序，并在可复现的三智能体清洗委员会上展示该方法。在感知固定时，确定性协调器可丢弃联合 Fisher 迹量级约一半；小的规则编辑（quarantine 处理、自动路径拆分、风险阈值）及其组合会以易于离线度量的幅度——包括沿各参数轴——移动该损失。配套实验装置与图旨在作为在变更在线流量前审计生产 if-then 委员会的模板。

未来工作包括：(i) 在同一 AggregationMap 接口下用 TypeSafe / 在线决策模型 Jacobian 替换解析智能体；(ii) 带显式条件动作模型的随机协调器；(iii) 在 JAAMAS 风格的经验研究中将 $\mathrm{tr}(\Delta_f)$ 与任务级效用耦合。

可复现性

从仓库根目录：

```
uv sync --locked
uv pip install matplotlib   # paper figures
uv run python examples/three_agent_cleaning/compare_rules.py
uv run python examples/three_agent_cleaning/paper_experiments.py
```

产物落在 `papers/coord-fisher/data` 与 `figures/`。本 PDF 由 lualatex 自 `papers/coord-fisher/main-zh.tex` 构建（英文版见 `main.tex`）。

References

Shun-ichi Amari. *Information Geometry and Its Applications*. Springer, 2016.

Micah Corah and Nathan Michael. Scalable distributed planning for multi-robot multi-target tracking. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2021.

Thomas M. Cover and Joy A. Thomas. *Elements of Information Theory*. Wiley, 2 edition, 2006.

R. A. Fisher. Theory of statistical estimation. *Mathematical Proceedings of the Cambridge Philosophical Society*, 22(5):700–725, 1925.

Jevometry maintainers. Jevometry: Information-geometric analysis of agent systems. Software library, 2026. https://github.com/Kunyanli230/Jevometry.

Andreas Krause, Ajit Singh, and Carlos Guestrin. Near-optimal sensor placements in gaussian processes: Theory, efficient algorithms and empirical studies. In *Journal of Machine Learning Research*, volume 9, pages 235–284, 2008.

Mikko Lauri and Frans A. Oliehoek. Multi-agent active perception with prediction rewards. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

Mikko Lauri, Joni Pajarinen, and Jan Peters. Multi-agent active information gathering in discrete and continuous-state decentralized POMDPs by policy graph improvement. *Autonomous Agents and Multi-Agent Systems*, 34:42, 2020. doi: 10.1007/s10458-020-09467-6.

Timothy L. Molloy and Girish N. Nair. Smoother entropy for active state trajectory estimation and obfuscation in POMDPs. *IEEE Transactions on Automatic Control*, 68(6):3550–3565, 2023.

George L. Nemhauser, Laurence A. Wolsey, and Marshall L. Fisher. An analysis of approximations for maximizing submodular set functions—I. *Mathematical Programming*, 14(1): 265–294, 1978.

Frans A. Oliehoek and Christopher Amato. *A Concise Introduction to Decentralized POMDPs*. Springer, 2016.

Jake Olkin, Viraj Parimi, and Brian Williams. Multi-agent vulcan: An information-driven multi-agent path finding approach. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2024.

Kunyan Shi, Wesley Suttle, Michael Dorothy, and Jie Fu. IMAS^2: Joint agent selection and information-theoretic sensing in dec-POMDPs. In *Proceedings of the International Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2026. Preprint; venue year as listed by authors.

Ram Zamir. A proof of the fisher information inequality via a data processing argument. *IEEE Transactions on Information Theory*, 44(3):1246–1250, 1998.